스마트 해운물류 x AI 미션 챌린지 : 이상신호 감지 기반 비정상 작동 진단

해양수산부 DACON



SKKU_SME_TM 팀 Solution PPT

Competition

목표: 센서 기반 데이터(X_01~X_52)로 장비의 정상/비정상 작동 유형을 분류하는 모델 개발

특성: 시계열 정보 X, 피처 비식별화, 다중 클래스 분류(21개 라벨)

평가 지표: Macro-F1

$$\text{Macro F1 Score} = \frac{\sum_{i=1}^{n} \text{F1 Score}_i}{n}$$

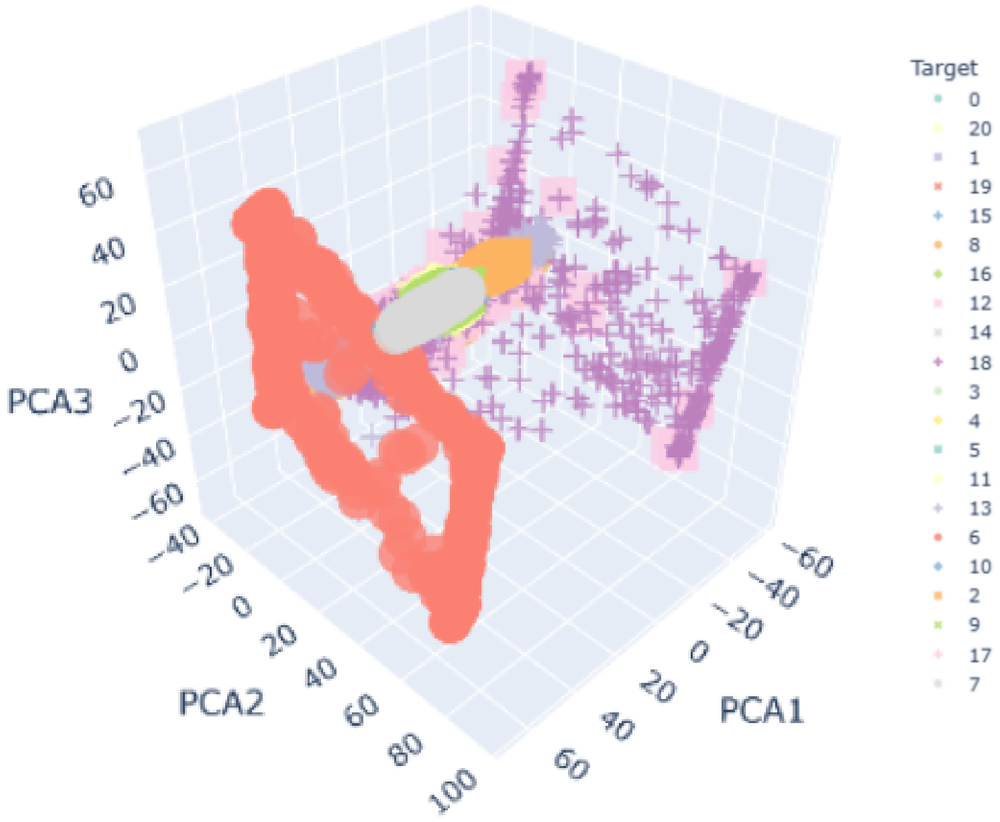


Data Structure & Characteristics

Input Features (X_01 ~ X_52)
다양한 센서 및 제어 신호 포함 (온도, 전류, 진동 등으로 추정)
피처명은 비식별화되어 제공됨 → 도메인 해석 어려움

Target Variable
총 21개 클래스(정상 + 비정상 유형)
클래스 간 의미 및 계층 관계는 공개되지 않음

데이터 특징
모든 샘플은 시계열 정보 없음 → 독립적 상태 판단만 가능
피처 간 상관관계 존재 → 다변량 해석 필요
도메인 지식 없이도 순수 통계 기반 판단 구조 필요



Challenge

베이즈라인 모델을 바탕으로 한 Confusion Matrix를 바탕으로
보았을때, 클래스 별 분류 난이도 상이

난이도 극상

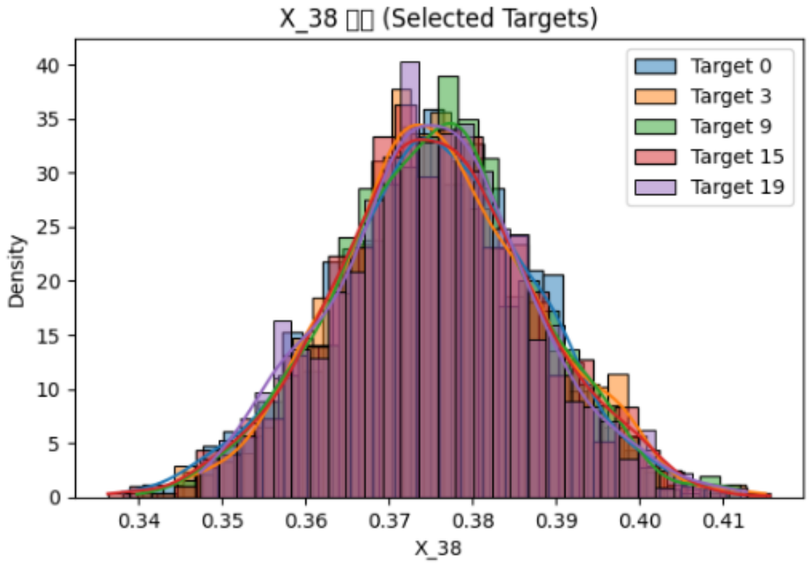
클래스 0,9,15

난이도 상

클래스 3,16

난이도 중

클래스 10,11,14

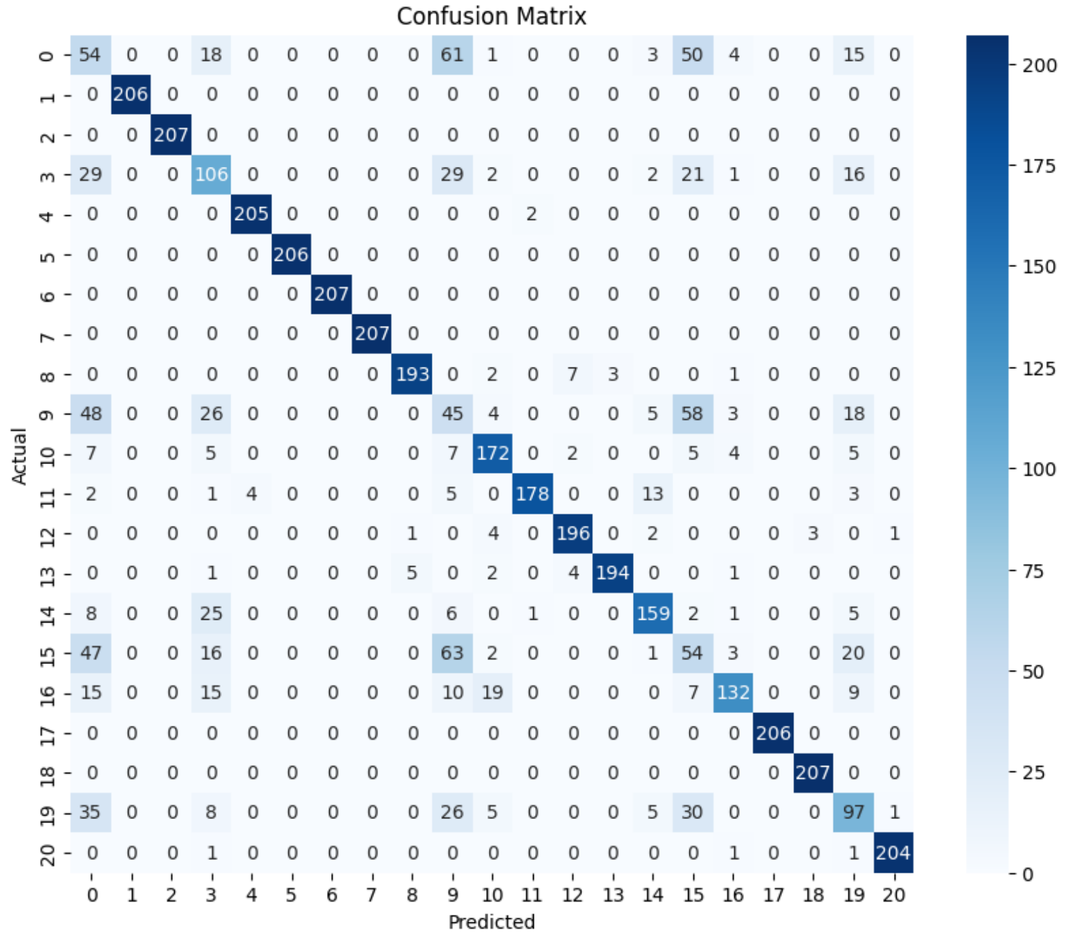


난이도 하

나머지 클래스 → 일부 클래스는 하나의 변수만으로도 완전 분류 가능

→ 고난이도 클래스로 예측 된 샘플 특화 분류기 3단 구축의 필요성 실감

→ 다양한 실험 끝에 최종 Solution 구축



Data Preprocessing Strategy

Why Standardization?

센서 데이터중 일부는 스케일이 다르므로, 선형변환에 기반한 PCA를 위해 스케일 보정은 필수

StandardScaler 사용 → 평균 0, 표준편차 1로 변환

모델 수렴 속도 향상, 차원 축소 기법 적용 가능성 증가



PCA: Principal Component Analysis

PCA는 데이터의 주요 분산 방향을 찾아내는 선형 변환 기반 분석 기법

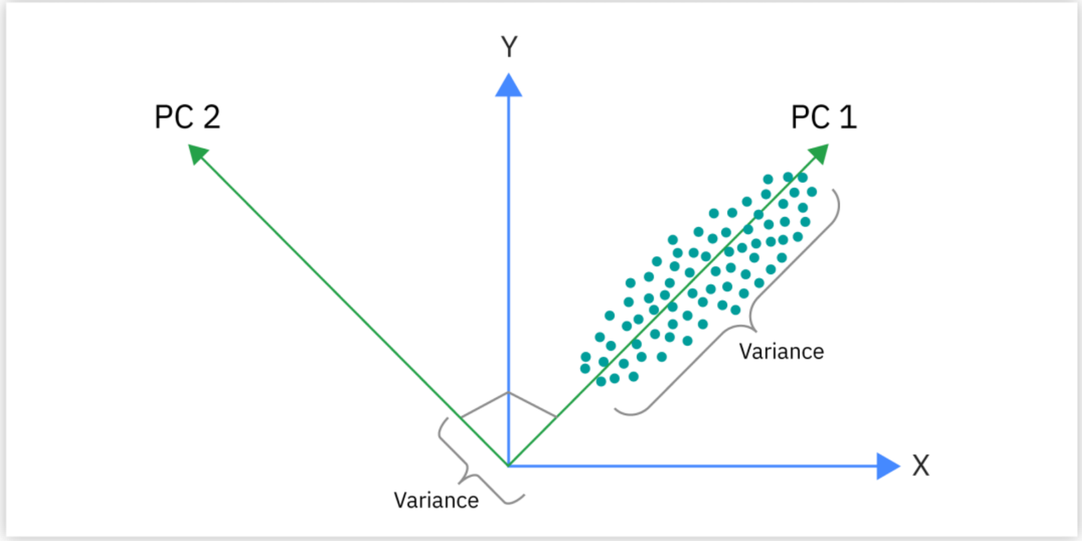
각 주성분은 서로 직교(orthogonal)하며,
데이터의 전체 분산을 가장 잘 설명하는 순서로 정렬

주요 효과

Noise Filtering
Information Compression
Numerical Conditioning
→ 초기 LB 성능 증가

$$Z = XW, \quad W = [w_1, w_2, ..., w_d]$$

X: 스케일링된 입력 데이터
W: 공분산 행렬의 고유벡터 (Principal Axes)
Z: PCA 변환된 데이터 표현 (직교 좌표계로 변환된 결과)



No Dimensionality Reduction with PCA

PCA를 적용하되 차원을 줄이지 않고 모든 주성분(52)을 사용 → 피쳐 셀렉시 정보손실로 인한 성능 저하 발생
단순한 압축이 목적이 아닌, 공간 회전 및 정규 직교화 자체가 목적

효과

다중공선성 제거
센서 피처 간 높은 상관관계를 제거하여 중복 정보 감소, 과적합 위험 감소
PCA 이후 각 주성분 간 완전 직교로 인해 공분산 행렬의 역행렬 계산 수치적 안정성 증가 → LDA 등 후속 알고리즘에 유리
원본 X는 상관된 피처들이 섞여 있지만, PCA 결과는 축 간 완전 직교로 인한 상관성 통제
Boosting 계열 모델(XGB 등)은 정규화된 독립 피처에 더 잘 수렴

LDA: Linear Discriminant Analysis

LDA는 클래스 분리 성능이 최대화되도록 선형 공간을 찾는 지도 학습 기반 차원 축소 기법
클래스 간 평균 분산은 크게, 클래스 내부 분산은 작게 → 이 비율을 최대로 하는 축을 찾음

클래스 간 분산 행렬: $S_B = \sum_k N_k(\mu_k - \mu)(\mu_k - \mu)^T$

클래스 내 분산 행렬: $S_W = \sum_k \sum_{x_i \in C_k} (x_i - \mu_k)(x_i - \mu_k)^T$

$\mathbf{w}$: **LDA 판별 벡터**, 데이터를 투영할 선형 방향(축)

$$\max_{\mathbf{w}} J(\mathbf{w}) = \frac{\mathbf{w}^\top \mathbf{S}_B \mathbf{w}}{\mathbf{w}^\top \mathbf{S}_W \mathbf{w}} \longrightarrow \mathbf{S}_B \mathbf{w} = \lambda \mathbf{S}_W \mathbf{w}$$

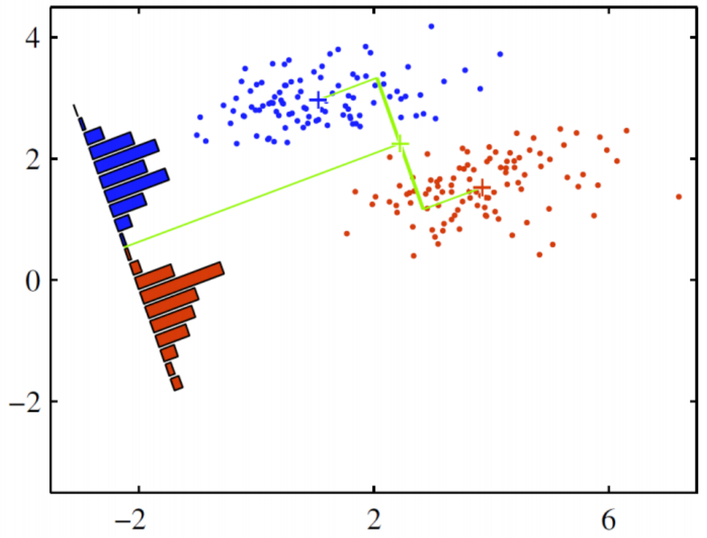
LDA - Feature Engineering

클래스 개수가 N개라면, LDA는 최대 $N-1$ 개의 선형 축(판별 벡터 $w_1, w_2, \ldots, w_{N-1}$)을 생성
따라서 **각 샘플 x_i**는 다음과 같은 $N-1$ 차원의 벡터로 변환됨:

$$z_i = \left[w_1^\top x_i,\ w_2^\top x_i,\ \ldots,\ w_{N-1}^\top x_i \right] \in \mathbb{R}^{N-1}$$

각 판별 축은 클래스 간 평균의 차이를 최대화하고, 클래스 내부 분산을 최소화하도록 최적화
이 축들에 데이터를 투영하면, 샘플들은 클래스 중심 간 거리 구조를 반영한 위치에 매핑
즉, 이 투영값들은 “샘플이 어느 클래스에 가까운가”에 대한 정보를 포함

각 LDA 피처는 복수 클래스 간 상대적 위치 정보를 정제된 형태로 표현
→ 후속 분류기 (XGB, CatBoost 등)는 이 정보에 기반해 더 정확한 분류 결정 경계를 학습 가능



Gaussian Log Likelihood - Feature Engineering

PCA 공간에서 각 클래스 c에 대해 **가우시안 분포** $\mathcal{N}(\mu_c, \Sigma_c)$를 적합
샘플 x에 대해 **클래스별 로그우도** 벡터 $\ell(x) = [\ell_1(x), \ldots, \ell_K(x)]$ 생성
차원: K (클래스 수만큼의 스칼라 점수)

클래스별 통계 추정:

$$\mu_c = \text{mean}(X_c), \quad \Sigma_c = \text{cov}(X_c) + \epsilon I$$

로그우도(상수항 제외)

$$\ell_c(x) \;=\; -\tfrac{1}{2}\left[(x-\mu_c)^\top \Sigma_c^{-1}(x-\mu_c) \;+\; \log|\Sigma_c|\right]$$

생성적 점수: x가 클래스 c의 분포에서 나올 법한가?"를 직접 수치화

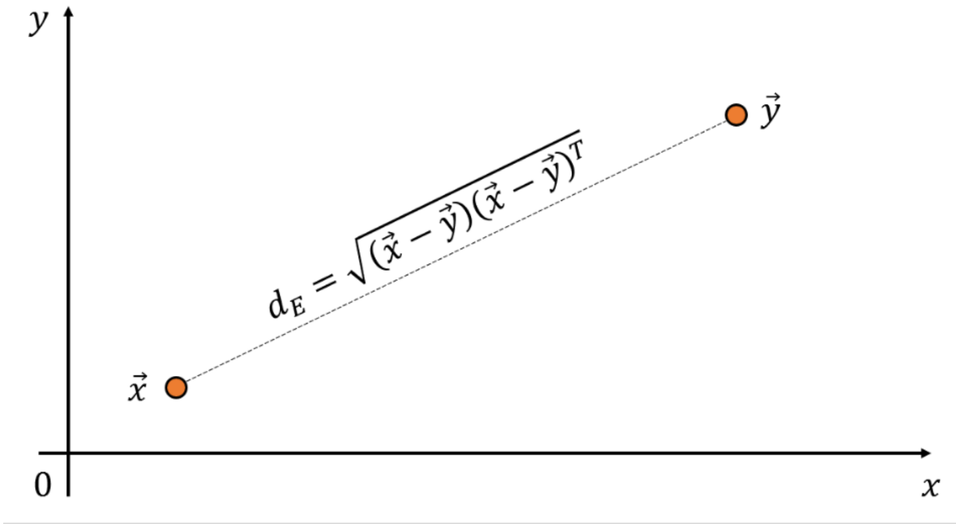
스케일/상관구조 반영: 축척·상관을 반영해 단순 유클리드보다 정교

분류기에 친화적: 클래스별 점수를 피처로 제공 → 의사결정 경계를 잡기 쉬움

Mahalanobis Distance - Feature Engineering

PCA 공간에서 각 클래스 중심 μ_c와 공분산 Σ_c 기준의 **마할라노비스 거리**
샘플 x에 대해 **클래스별 거리** 벡터 $d(x) = [d_1(x), \ldots, d_K(x)]$ 생성
차원: K

$$d_c(x) = \sqrt{(x - \mu_c)^\top \Sigma_c^{-1} (x - \mu_c)}$$



로그우도와 상보성: 로그우도와 단조 관계(로그항 차이)지만,
수치적 안정성과 결정경계 보정에 실전적으로 도움
분리 힌트 강화: 어느 클래스 중심에 더 가까운가를 직접 거리로 제공

Feature Store

1. Raw Feature

2. PCA (주성분 분석) Feature

3. LDA (선형 판별 분석) Feature

4. Log-Likelihood Feature

5. Mahalanobis Distance Feature



Model Strategy

모델 구성 개요: Multiclass 3-Stage Ensemble

Stage 1: Base Classifier (21개 전체 클래스 분류)
입력: 원본 피처 + PCA 변환 + LDA + + log likelihood + 마할라노비스 거리
모델: XGBoost (CV 5fold 앙상블)
출력: 21개 클래스 확률 분포
목적: 전체 클래스 coarse 분류

Stage 2: MID 클래스 전용 재분류 (9개 클래스-> 0,3,9,10,11,14,15,16,19)
대상: Stage 1에서 MID 9클래스로 예측된 샘플
특성: PCA + LDA + log likelihood + 마할라노비스 거리
모델: XGBoost (CV 5fold 앙상블)
목적: 헷갈리는 클래스 간 정밀 분류

Stage 3: HARD 클래스 전용 고정밀 재분류 (6개 클래스->0,3,,9,15,16)
대상: Stage 2에서 HARD 6클래스로 예측된 샘플
특성: 동일하게 PCA + LDA + log likelihood + 마할라노비스
모델: XGBoost (CV 5fold 앙상블)
목적: 극난이도 클래스 간 최종 정밀 예측

-> 최종 LB Private Score = Macro F1 87.793

